SpecForge：基于知识蒸馏与推测解码的 Transformer CPU 推理优化系统 独立开发

技术栈：PyTorch；Speculative Decoding；Knowledge Distillation；KV Cache；Rejection Sampling；Survival Analysis；Bellman Dynamic Programming；CPU Profiling

项目背景：针对大模型自回归解码在 batch=1 场景下逐 token 调用目标模型的问题，构建“草稿候选生成—目标模型并行验证—接受/拒绝修正—KV Cache 回滚”的完整推测解码（Speculative Decoding）闭环，并以风险集统计口径、成本模型与输出分布等价检验支撑全部性能结论。

工作内容与成果：

- **双模型与增量推理：**从零实现 Target Transformer（**4,828,928** 参数，$d=256, L=6, H=8$）与 Draft Transformer（**159,440** 参数，$d=80, L=2, H=4$），参数压缩比 30.29×；实现分块因果注意力、逐层 KV Cache 增量前向和 `truncate` 回滚。
- **蒸馏训练：**实现 SFT → 温度缩放混合蒸馏（$T=2.0, \alpha=0.75$）与可切换的 TV-aware 目标（直接优化 $\sum \min(p,q)$）；验证集 Top-1 agreement **98.35%**，$\mathrm{KL}(T\|S)$ **0.0480**；4 目标 × 2 seed 消融证实 Pinsker 下界在全部目标上成立。
- **接受过程生存分析：**发现并修正旧口径 accepted/proposed 将右删失 token 计入拒绝的统计错误，改为**风险集口径 accepted/verified**；用 Kaplan–Meier 估计逐位置 hazard 并做似然比检验，实测接受率稳定在 **98.6%–99.2%**、常数 hazard 不被拒绝，有限长度 Monte Carlo 与实测目标调用平均绝对误差 **0.172** 轮。
- **成本感知自适应 K：**逐轮实测块成本 $C(K)$（$R^2=0.986$），以 $K^*=\arg\min C(K)/(E[A(K)]+1)$ 与有限时域 Bellman 方程 $V(n)=\min_K[C(K)+E[V(n-A-1)]]$ 求最优策略，固定 K 为其策略子集；calibration/held-out 强制分离，双模式均按此协议报告：贪婪模式校准选出 K=32，held-out 实测 2.358×（**CI** [2.02, 2.78]）加速，输出 **100%** 逐 token 等价（正确性锚点）。
- **分布偏移压力测试：**构造高熵语料（条件熵 0.637→1.668）重训双模型，接受率由 98% 跌至 70%、最优加速由 2.297× 跌至 0.707×（负加速），证明原加速高度依赖低熵语料；hazard 偏移下自适应策略将固定 K=28 的 0.760× 负加速修正为 0.927×。
- **随机模式基准与等价检验：**随机拒绝采样作为第二正式基准，held-out 2.723×（**CI** [2.64, 2.79]），正确性判据为解码器级输出分布等价检验（TV=0.030，参数自助 p=1.0 不拒绝等价），与贪婪模式的序列等价判据明确区分；归因对照量化 dispatch 摊销占比 **92.3%**，并报告 target token ratio（K=32 时 114.6%）。
- **可观测性与复现：**自动采集 TTFT、延迟 P50/P95、风险集接受率、右删失比例、回滚率、目标调用数与双 KV Cache 峰值 token；**46 个单元测试全部通过**，全部结论由一键研究流水线复现。

说明：数据来自程序化中文技术语料、自研微型 Transformer 与固定单线程 CPU 自建离线基准，全部数字带自助置信区间并可一键复现；用于验证算法与工程闭环，不表述为生产大模型线上收益。